

UNIVERSITÀ DEGLI STUDI DI SALERNO

Dipartimento di Scienze Economiche e Statistiche

Corso di Laurea Triennale in Statistica per i Big Data

Prova finale in
Modelli Statistici

IMPATTO DELLA RICEZIONE NEL CAMPIONATO DI SERIE D: IL CASO STUDIO VOLLEY SALERNO NELLA STAGIONE 2023/2024

Relatore:
Ch.ma Prof.ssa
Marcella Niglio

Candidato:
Simone Squizzato
matr. 0212801023

ANNO ACCADEMICO 2023/2024

Indice

Introduzione 1

1 Introduzione alla statistica per lo sport 2
- 1.1 L'importanza dei dati nello sport moderno: l'effetto Moneyball 2
- 1.2 Evoluzione del gioco della pallavolo 3
- 1.3 L'organizzazione della pallavolo maschile italiana 4
- 1.4 Evoluzione del numero di tesserati FIPAV 4
- 1.5 Il campionato di Serie D campano nella stagione 23/24 5

2 Modelli di regressione con variabile dipendente limitata 7
- 2.1 Introduzione ai modelli di regressione 7
- 2.2 Modelli a variabile dipendente limitata 7
- 2.3 Modello di regressione logistica 9
  - 2.3.1 Stima dei parametri 10
  - 2.3.2 Odds Ratio 12
- 2.4 Valutazione della bontà di adattamento del modello 12
  - 2.4.1 Pseudo-R^2 12
  - 2.4.2 Analisi dei residui 13
- 2.5 Valutazione della capacità predittiva del modello 13
  - 2.5.1 Elementi della matrice di confusione 14
  - 2.5.2 Curva ROC e AUC 16

3 Caso studio: Volley Salerno nella stagione 23/24 18
- 3.1 Metodologie di raccolta dei dati 18
- 3.2 Analisi esplorativa dei dati 18
  - 3.2.1 Analisi grafica 21
- 3.3 Stima del modello logit 23
  - 3.3.1 Interpretazione della stima dei parametri 24
  - 3.3.2 Analisi degli OddsRatio 25
  - 3.3.3 Diagnostica sulla collinearità 26
  - 3.3.4 Analisi dei residui 28
  - 3.3.5 Analisi dei valori anomali 29
  - 3.3.6 Valutazione della bontà di adattamento e delle performance previsive 31
- 3.4 Conclusioni e sviluppi futuri 31

Elenco delle figure

Figura 1.1: Graduatoria federazioni sportive nazionali per numero di tesserati . . 5

Figura 2.1: Curva ROC ottimale 16

Figura 3.1: Suddivisione in zone del campo di pallavolo 19
Figura 3.2: Schema di assegnazione del punteggio alla ricezione per area 20
Figura 3.3: Pair Plot delle variabili numeriche 21
Figura 3.4: Distribuzione della zona di ricezione 22
Figura 3.5: Distribuzione dello score della ricezione 22
Figura 3.6: Distribuzione dello score della ricezione condizionato all'esito del punto 23
Figura 3.7: Distribuzione dei punti per angolo di ricezione 23
Figura 3.8: Distribuzione della modalità di conclusione del punto rispetto all'esito 24
Figura 3.9: Plot degli OddsRatio 26
Figura 3.10: Binnedplot dei residui 28
Figura 3.11: Q-Q Plot dei residui 29
Figura 3.12: Marginal Model Plot 29
Figura 3.13: Plot dei residui vs fitted values 30
Figura 3.14: Influence Plot 30
Figura 3.15: Curva ROC 33

Elenco delle tabelle

Tabella 1.1: Classifica finale Girone A 6

Tabella 2.1: Matrice di confusione 14

Tabella 3.1: Stima dei parametri del modello logit e significatività 25
Tabella 3.2: Stima degli OddsRatio e significatività 26
Tabella 3.3: Tolerance and Variance Inflation Factor 27
Tabella 3.4: Autovalori e Condition Index 28
Tabella 3.5: Output OutlierTest 30
Tabella 3.6: Output Influnce Plot 31
Tabella 3.7: PseudoR^2 31
Tabella 3.8: Matrice di confusione 32
Tabella 3.9: Statistiche curva ROC e AUC 32

Introduzione

L'analisi quantitativa dei dati è divenuta una componente fondamentale nel panorama sportivo, in particolare nei campionati professionistici di pallavolo, dove l'utilizzo dei Big Data ha profondamente influenzato le strategie di gioco delle squadre. Tale sviluppo tecnologico ha permesso di modellare e prevedere con maggiore accuratezza le dinamiche del gioco, contribuendo ad un'evoluzione tattica significativa. Questo lavoro di tesi si inserisce in tale contesto, applicando un modello logit per indagare la probabilità di vittoria del punto in fase di cambio-palla nella pallavolo dilettantistica italiana, con un focus specifico sulla Serie D campana.

L'obiettivo della ricerca è quello di determinare i principali fattori predittivi che influenzano la vittoria del punto, utilizzando variabili come la qualità della ricezione e il coinvolgimento degli attaccanti nel gioco. Attraverso l'analisi dei dati raccolti, il modello logit permette di stimare l'impatto di questi predittori, fornendo una comprensione più profonda delle dinamiche di gioco a livello dilettantistico. I risultati ottenuti potrebbero offrire spunti utili non solo per il miglioramento delle performance delle squadre di Serie D, ma anche per una riflessione più ampia sull'applicazione dei metodi analitici nel contesto dello sport dilettantistico, suggerendo potenziali linee di sviluppo per il futuro.

1 Introduzione alla statistica per lo sport

1.1 L'importanza dei dati nello sport moderno: l'effetto Moneyball

Quando si affronta il tema della statistica applicata allo sport, uno dei primi esempi che viene in mente è Moneyball (in Italia noto come "L'arte di vincere"), il film del 2011, tratto dall'omonimo libro di Michael Lewis, con Brad Pitt nel ruolo di protagonista. La pellicola narra la storia di Billy Beane, General Manager degli Oakland Athletics, che, nei primi anni duemila, attraverso l'uso delle analisi statistiche, rivoluzionò le tecniche di scouting e la percezione del gioco del baseball. Questo avvenimento segnò un punto di svolta, coincidente con l'aumento della capacità di calcolo dei moderni computer, ormai accessibili anche al grande pubblico, che contribuì alla diffusione della cultura dell'analisi statistica applicata allo sport.

L'origine dell'uso della statistica nello sport, in un contesto come quello del baseball, è riconducibile alla semplicità e alla rigidità degli schemi di gioco, riducibili a un'interazione tra due soli attori, il lanciatore e il battitore. Tale caratteristica ha facilitato l'analisi e la costruzione di metriche specifiche per la valutazione delle performance dei singoli giocatori. Questa rivoluzione ha avuto un impatto particolarmente significativo negli Stati Uniti, dove ne è stato influenzato anche il basket; l'analisi dell'impatto dei tiri da tre punti ha portato alla nascita del cosiddetto "Moreyball", dal nome di Daryl Morey, un pioniere in questo campo, modificando in maniera irreversibile la distribuzione delle posizioni da cui venivano tentati i canestri e le tattiche di gioco. Negli anni successivi, l'avvento dei Big Data ha esteso tali innovazioni anche in Europa e in altri sport, come il calcio, la Formula 1 e la pallavolo.

Attualmente, l'industria della statistica applicata allo sport è un mercato dal valore stimato di tre miliardi di dollari ed è destinato a una forte espansione nei prossimi anni. Questo fenomeno riflette la crescente necessità, da parte degli operatori del settore, di prendere decisioni basate sui dati riguardo la gestione di giocatori e infrastrutture, che sono ormai considerati veri e propri asset per le proprietà e i club.

Tale cultura sta guadagnando terreno anche nelle categorie minori dei principali sport a livello mondiale. Tuttavia, in Italia, il panorama è ancora dominato da realtà di dimensioni modeste, che difficilmente riescono a sfruttare in modo efficace questo nuovo approccio analitico. Le principali eccezioni si riscontrano nel calcio, grazie ai consistenti investimenti nel settore e alla possibilità di recuperare tali investimenti attraverso la valorizzazione delle strutture e dei giocatori. In altri sport, di minore rilevanza e caratterizzati da investimenti ridotti, l'adozione di strumenti analitici per supportare le decisioni risulta più complessa, ciò accade anche per la pallavolo.

Per comprendere le ragioni di questa difficoltà, è utile focalizzare l'attenzione sull'evoluzione che il gioco ha subito nel corso del tempo.

1.2 Evoluzione del gioco della pallavolo

Il gioco della pallavolo, come lo conosciamo oggi, è il risultato di un costante processo di adattamento e revisione delle regole, che ha permesso un'evoluzione continua di questo sport, rendendolo sempre più apprezzabile sia per gli atleti sia per gli spettatori. Rispetto alla versione originaria della pallavolo, ideata nel 1895 da William G. Morgan, la pallavolo moderna ha subito numerosi cambiamenti. Una tappa cruciale nello sviluppo di questo sport è rappresentata dalla creazione della Federazione Internazionale di Pallavolo (Fédération Internationale de Volleyball, FIVB) a Praga nel 1947, quando venne ufficialmente approvato il primo regolamento internazionale che unificava le regole di gioco europee e americane.
Nel corso degli anni, molte modifiche regolamentari hanno influenzato significativamente il gioco, ma la riforma che ha segnato il progresso più importante in termini di diffusione e popolarità è indubbiamente quella introdotta nel 1998, che ha portato gli ultimi grandi cambiamenti. A partire dalla stagione sportiva 1999/2000, le principali modifiche regolamentari includevano:

1. La sostituzione del vecchio sistema di punteggio "cambio-palla" (da non confondere con la fase di cambio-palla che vedremo successivamente) con il moderno "Rally Point System", in cui ogni azione assegna un punto, indipendentemente da quale squadra sia al servizio. Se la squadra in ricezione vince l'azione, oltre a guadagnare il punto, acquisisce anche il diritto a servire, ruotando di una posizione in senso orario.
2. La revisione della formula di gioco, che prevede la vittoria al meglio dei 5 set. Nei primi quattro set, vince la squadra che raggiunge 25 punti con uno scarto minimo di 2 punti. In caso di parità 24-24, il gioco continua fino a quando una delle due squadre non ottiene i due punti di vantaggio necessari. Se i set sono in parità 2-2, il quinto set, decisivo, si gioca a 15 punti con le stesse condizioni di scarto minimo.
3. La modifica del sistema di punteggio per le vittorie nei campionati: tre punti sono assegnati alla squadra che vince 3-0 o 3-1; due punti alla squadra che vince 3-2; un punto alla squadra che perde 2-3 e nessun punto è assegnato alla squadra che perde 1-3 o 0-3.
4. La conferma dell'applicazione della regola del "Libero", introdotta nella stagione 1997/1998, in tutti i campionati e categorie.
5. La modifica riguardante il fondamentale della battuta: è stato stabilito che la palla, nel superare la rete, può toccarla senza che ciò venga considerato fallo.

Queste variazioni al regolamento non solo hanno avuto un impatto significativo a livello tattico, ma hanno anche reso il gioco della pallavolo più entusiasmante e coinvolgente, grazie alla riduzione della durata delle partite originato dal cambiamento del sistema di punteggio.
Nella relativamente giovane storia dell'attuale regolamento della pallavolo, si può individuare una delle ragioni per cui l'analisi delle situazioni di gioco è meno diffusa e documentata rispetto ad altri sport, soprattutto nell'ambito delle squadre maschili.
Conclusa questa panoramica sull'evoluzione del gioco della pallavolo, passiamo all'analisi dell'organizzazione della pallavolo maschile in Italia.

1.3 L'organizzazione della pallavolo maschile italiana

L'organo istituzionale responsabile dell'organizzazione dei campionati di pallavolo maschile in Italia è la Federazione Italiana Pallavolo, comunemente nota con l'acronimo FIPAV o FederVolley. L'attuale configurazione della FIPAV risale al 31 marzo 1946 e, dall'agosto dell'anno successivo, essa è parte integrante del Comitato Olimpico Nazionale Italiano (CONI). La struttura della FIPAV è articolata in diversi comitati di carattere regionale e territoriale, i quali gestiscono i campionati a tutti i livelli.
I campionati sono gerarchicamente suddivisi in tre principali categorie: Nazionali, Regionali e Territoriali. All'interno della categoria Nazionale, si collocano i campionati di Serie A, che sono ulteriormente suddivisi in tre livelli: Superlega, A2 e A3; tali campionati sono gestiti dalla Lega Pallavolo Serie A su mandato della Federazione. Successivamente, si trova il campionato di Serie B, gestito dalla Lega Nazionale Pallavolo. Per quanto riguarda i campionati Regionali, essi comprendono la Serie C e la Serie D, i quali sono amministrati dagli organi regionali della FIPAV. Infine, vi sono i tornei minori di Prima, Seconda e Terza divisione, che sono organizzati e gestiti dai comitati territoriali, analogamente a tutte le competizioni giovanili.
Nel presente studio, particolare attenzione sarà rivolta al campionato di Serie D della regione Campania, contesto nel quale si inserisce l'analisi del caso studio esaminato nel Capitolo 3.

1.4 Evoluzione del numero di tesserati FIPAV

In relazione ai cambiamenti regolamentari avvenuti a partire dall'anno 2000, che hanno reso la pallavolo uno sport adatto anche alla trasmissione televisiva delle partite, valutiamo l'impatto di questi ultimi sul numero di tesserati della Federazione negli anni succesivi, fino al 2023.
L'analisi del numero di tesserati della FIPAV dal 2000 al 2023 mostra un quadro articolato, segnato da variazioni significative sia nel numero totale dei tesserati sia nella composizione per genere. Nel periodo compreso tra il 2000 e il 2009, si è osservato un forte incremento dei tesserati totali, passando da 199,240 a 327,031 (+64.1%). Tale aumento è stato trainato soprattutto dalle atlete tesserate, aumentate dell'83.2%, mentre per la controparte maschile la crescita è stata minore, pari solo al 26.1%. La tendenza ha continuato a favorire il settore femminile anche nel lustro successivo: dal 2010 al 2015 il numero delle atlete tesserate è aumentato del 17.3%, raggiungendo un picco di 288,312 (e un totale di 373,705 tesserati). Successivamente, tra il 2015 e il 2019, sia il numero di tesserati maschi che quello delle femmine ha subito un calo, rispettivamente del 16% e del 14.3%, portando il numero totale di tesserati a 322.378 nel 2019.
L'impatto della pandemia di COVID-19 è stato drammatico, con un crollo significativo del numero di tesserati nel 2021: i tesserati maschi sono scesi a 51,441, mentre le femmine a 168,188, determinando un minimo storico di 219,629 tesserati totali. Tuttavia, si è verificata una ripresa nelle stagioni successive, con un aumento del totale dei tesserati tra il 2021 e il 2023, che ha permesso di superare addirittura i livelli pre-pandemia, portando il numero complessivo di tesserati a 334,770.

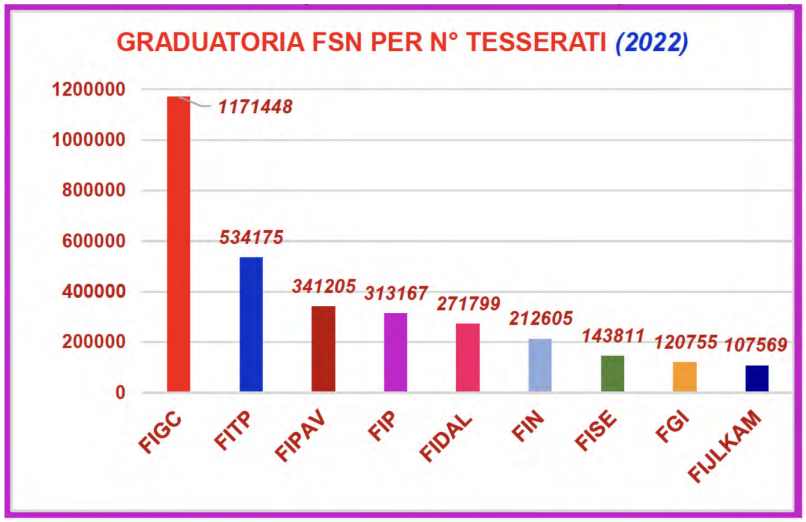


Figura 1.1: Graduatoria federazioni sportive nazionali per numero di tesserati

Il report, fornito dall'osservatorio della FIPAV, in ultima parte permette anche di valutare l'impatto complessivo che la pallavolo ha come sport a livello nazionale; ciò avviene attraverso il confronto con il numero di tesserati con le altre principali Federazioni Sportive Nazionali (FNS) affiliate al CONI all'anno 2022 osservabili nella Figura 1.1.
In termini assoluti la pallavolo occupa il terzo posto per numero di tesserati, tra la FIPAV e la FIGC (Federazione Italiana Giuoco Calcio) ritroviamo la FITP (Federazione Italiana Tennis e Padel) con poco meno di 200,000 tesserati in più rispetto alla FIPAV, dovuti anche al cosiddetto "Fenomeno Padel" scoppiato in seguito alla pandemia.
In particolare, un confronto tra i tesserati della FIPAV e della FIGC evidenzia differenze marcate in termini di quantità e distribuzione per genere. Nel 2022, la FIGC contava 1.117.448 tesserati, una cifra significativamente superiore rispetto ai 322.000 circa della FIPAV. Inoltre, mentre nella FIPAV vi è una predominanza del genere femminile, con oltre il 75% del totale dei tesserati, la FIGC rimane fortemente maschile, con una presenza femminile molto meno rilevante. Questo divario riflette non solo la diversa natura delle due discipline, ma anche le tradizioni culturali e sociali che le accompagnano in Italia. Mentre il calcio continua a essere lo sport più popolare e praticato a livello nazionale, la pallavolo emerge come uno sport inclusivo, con una crescente partecipazione femminile che la distingue nettamente nel panorama sportivo italiano.
La predominanza della componente femminile nel contesto della pallavolo italiana rappresenta una delle ragioni fondamentali che hanno guidato l'analisi e la selezione del caso studio presentato nel Capitolo 3. Tale scelta risponde all'esigenza di colmare una lacuna nella ricerca accademica riguardante il settore specifico esaminato.

1.5 Il campionato di Serie D campano nella stagione 23/24

È fondamentale introdurre il contesto in cui sono stati raccolti e utilizzati i dati analizzati nel Capitolo 3. Il campionato di Serie D della regione Campania, relativo alla stagione

sportiva 2023/2024, è composto da ventidue squadre suddivise in due gironi di undici squadre ciascuno (Girone A e Girone B). Ogni squadra affronta le altre dieci del proprio girone in un totale di venti partite, suddivise in incontri di andata e ritorno, comunemente indicati come regular season. Al termine della regular season, le squadre che si classificheranno al primo posto di ciascun girone otterranno la promozione diretta al campionato di Serie C per la stagione sportiva 2024/2025. Le squadre classificate al secondo e al terzo posto di ogni girone, invece, accederanno alla seconda fase del torneo, denominata play-off; i play-off si articolano in una serie di partite al meglio di tre, che determineranno l'assegnazione degli ultimi due posti disponibili per la promozione in Serie C.
Le ultime tre squadre di ciascun girone, al termine della regular season, retrocederanno nei rispettivi campionati provinciali di Prima Divisione. In caso di parità punti, la classifica finale sarà determinata dai risultati degli scontri diretti.
Considerando i gironi della competizione, con particolare riferimento al Girone A, in cui è inclusa la squadra oggetto della nostra analisi, l'A.S.D. Volley Salerno Official, la Tabella 1.1 riporta il piazzamento finale delle squadre. Tale informazione sarà utile per interpretare alcuni dei risultati discussi nel Capitolo 3. Dall'analisi della classifica finale emerge che l'A.S.D. Volley Salerno Official ha concluso il campionato al quarto posto, un piazzamento insufficiente per l'accesso ai play-off, obiettivo invece raggiunto dalle squadre Com Cavi Volley Meta e Polisportiva Pessy. Di queste, solo la prima è riuscita a ottenere la promozione in Serie C attraverso la seconda fase del torneo. Le squadre retrocesse sono invece Sparanise Volley, UISP Volley Ercolano e Virtus Aversa, quest'ultima a causa dei risultati sfavorevoli negli scontri diretti contro l'A.S.D. Cava Volley.

Tabella 1.1: Classifica finale Girone A

Pos.	**Squadra**	**Punti**
1	ASD Volley Volla	51
2	Com Cavi Volley Meta	47
3	Polisportiva Pessy	44
4	ASD Volley Salerno Official	40
5	Guancia Volley Academy	36
6	Ares ASD	27
7	Flat Sport	24
8	ASD Cava Volley	21
9	Virtus Aversa	21
10	UISP Volley Ercolano	16
11	Sparanise Volley	3

2 Modelli di regressione con variabile dipendente limitata

2.1 Introduzione ai modelli di regressione

La regressione lineare è uno degli strumenti statistici più utilizzati per analizzare la relazione tra una variabile dipendente e una variabile indipendente. Alla base di questo modello vi è l'assunto che esista una relazione lineare tra le variabili in esame, espressa matematicamente dall'equazione:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_n X_n + \epsilon \tag{2.1}$$

dove Y rappresenta la variabile dipendente, $X_1, X_2, \ldots, X_n$ sono le variabili indipendenti, β_0 è l'intercetta, $\beta_1, \beta_2, \ldots,$ sono i coefficienti di regressione che quantificano l'impatto di ciascuna variabile indipendente su Y, ed ϵ è il termine di errore, che cattura la variazione di Y non spiegata dal modello.
L'attrattiva del modello di regressione lineare risiede nella sua semplicità e nella facilità con cui i parametri possono essere interpretati. Ogni coefficiente β_i rappresenta l'effetto marginale di un'unità di aumento della variabile X_i su Y, assumendo che tutte le altre variabili restino costanti. Questo permette di effettuare inferenze significative sulle relazioni tra le variabili, facilitando la comprensione dei fenomeni studiati.
Sebbene la regressione lineare rappresenti una base solida per l'analisi delle relazioni tra variabili, essa presenta alcune limitazioni, in particolare quando la variabile dipendente non è continua o non assume valori su un intervallo illimitato. In queste circostanze, la sua applicazione può risultare inadeguata e può portare a previsioni inverosimili o a interpretazioni fuorvianti. Per affrontare tali situazioni, è necessario considerare modelli di regressione con variabile dipendente limitata, come i modelli Logit e Probit, che estendono l'analisi a contesti dove la variabile dipendente è binaria o categoriale. Nella sezione successiva, verrà approfondito uno di questi modelli avanzati, in particolare il modello Logit.

2.2 Modelli a variabile dipendente limitata

I modelli a variabile dipendente limitata, noti anche come modelli a scelta discreta, sono modelli in cui la variabile dipendente è una variabile binaria che rappresenta l'esito di un evento, con un successo o un insuccesso. In altre parole, si osserva la presenza o l'assenza di un determinato risultato, costruito in modo che gli esiti siano mutuamente esclusivi. Ad esempio, l'esito di un evento, che nel nostro caso risulterà nella conquista o meno di un punto giocato, può essere rappresentato da una variabile indicatrice del tipo:

$$Y_i = \begin{cases} 1 & \text{se l'evento si è verificato} \\ 0 & \text{se l'evento NON si è verificato} \end{cases} \tag{2.2}$$

Essendo Y_i una variabile binaria, essa segue una distribuzione bernoulliana, ossia:

$$Y_i \sim Be(p_i) \tag{2.3}$$

dove la probabilità p_i è data da

$$P(Y_i = 1) = p_i \tag{2.4}$$

che rappresenta la probabilità di successo dell'evento i-esimo. La probabilità di insuccesso, ossia che l'evento non si verifichi, è:

$$P(Y_i = 0) = 1 - p_i \tag{2.5}$$

La distribuzione di probabilità della variabile indicatrice binaria Y_i, essendo una variabile casuale bernoulliana, è:

$$f(Y_i) = p_i^{Y_i} * (1 - p_i)^{1-Y_i} \tag{2.6}$$

Il suo valore atteso sarà pari a:

$$E(Y_i) = p_i \tag{2.7}$$

E la sua varianza è

$$Var(Y_i) = p_i * (1 - p_i) \tag{2.8}$$

A questo punto, possiamo costruire un modello che ci aiuti a spiegare l'esito dell'evento e a stimare la probabilità di successo. Siamo quindi interessati a comprendere le cause che determinano un esito positivo e a identificare i fattori che influenzano il processo decisionale, vogliamo anche sapere in che misura ciascun fattore incide sull'esito finale.
L'obiettivo è stimare, quindi, p_i e individuare i fattori (caratteristiche) che possono influenzare la probabilità di successo di un evento.
Il modello da costruire deve considerare un insieme di fattori che spieghino l'esito osservato. Sarà un modello del tipo:

$$p_i(\mathbf{x}_i') = P(Y_i = 1|\mathbf{x}_i') = F(\mathbf{x}_i'\beta) \tag{2.9}$$

Con $\mathbf{x}_i'$ vettore colonna delle k variabili indipendenti (esplicative) e β vettore colonna dei k coefficienti incogniti da stimare, associati alle variabili indipendenti.
Come anticipato, i coefficienti riflettono l'impatto dei cambiamenti in $\mathbf{x}_i'$ sulla probabilità p_i. Tale modello deve essere capace di tenere conto dei fattori che influenzano l'esito. È per giunta naturale che:

$$1 - p_i(\mathbf{x}_i') = P(Y_i = 0|\mathbf{x}_i') = 1 - F(\mathbf{x}_i'\beta) \tag{2.10}$$

Quindi la funzione $(\mathbf{x}_i'\beta)$ gioca un ruolo fondamentale nel modello:

$$Y_i = F(\mathbf{x}_i'\beta) + e_i \quad \forall i \tag{2.11}$$

L'obiettivo risulta essere quello di individuare il modello adatto per $F(\mathbf{x}_i'\beta)$. Al variare della funzione di ripartizione F, cambieranno le caratteristiche, il metodo di stima e l'interpretazione del modello.

2.3 Modello di regressione logistica

In questo contesto si inserisce il modello di regressione logistica, dove la funzione di ripartizione utilizzata, indicata con F, è la funzione di ripartizione logistica, legata alla variabile casuale logistica $\Lambda(\cdot)$:

$$p_i = P(Y_i = 1|\mathbf{x}_i') = F(\mathbf{x}_i'\beta) = \Lambda(\mathbf{x}_i'\beta) \tag{2.12}$$

Che ci permette di scrivere il modello come:

$$Y_i = \Lambda(\mathbf{x}_i'\beta) + e_i \quad \forall i \tag{2.13}$$

Prima di proseguire ulteriormente, introduciamo qualche informazione sulla variabile casuale logistica. Una variabile casuale X con funzione di densità:

$$\lambda(x) = \frac{1}{\delta} e^{-\frac{x-\lambda}{\delta}} (1 + e^{-\frac{x-\lambda}{\delta}})^{-2} \tag{2.14}$$

per $-\infty < x < +\infty$, $\delta > 0$ (parametro di variabilità) e $-\infty < \lambda < +\infty$ (parametro di posizione), è detta Logistica con parametri (λ, δ) e si scrive $X \sim \Lambda(\lambda, \delta)$.
La variabile casuale logistica è simmetrica rispetto al parametro λ, per cui la media, la mediana e la moda coincidono con λ. La varianza è uguale a $\frac{\pi^2}{3}\delta^2$. Essendo simmetrica, l'asimmetria è zero, mentre la curtosi è uguale a $\frac{6}{5}$, quindi la distribuzione è leptocurtica.
La funzione di ripartizione è data da:

$$\Lambda(x) = \frac{1}{1 + e^{-\frac{x-\lambda}{\delta}}} \tag{2.15}$$

Nel caso della regressione logistica, si considera $\lambda = 0$ e $\delta = 1$, per cui la funzione di ripartizione diventa:

$$\Lambda(x) = \frac{1}{1 + e^{-x}} = \frac{e^x}{1 + e^x} \tag{2.16}$$

Pertanto, nel modello di regressione logistica abbiamo:

$$p_i = P(Y_i = 1|\mathbf{x}_i') = F(\mathbf{x}_i'\beta) = \Lambda(\mathbf{x}_i'\beta) = \frac{e^{\mathbf{x}_i'\beta}}{1 + e^{\mathbf{x}_i'\beta}} \tag{2.17}$$

E

$$1 - p_i = P(Y_i = 0|\mathbf{x}_i') = 1 - F(\mathbf{x}_i'\beta) = 1 - \Lambda(\mathbf{x}_i'\beta) = \frac{1}{1 + e^{\mathbf{x}_i'\beta}} \tag{2.18}$$

Come si nota, la funzione di media condizionata $E(Y_i|\mathbf{x}_i')$ non è lineare nelle variabili esplicative e nei parametri, tuttavia è possibile passare da un modello non lineare a un modello lineare. Sappiamo che $p_i \in [0,1]$; possiamo considerare una quantità chiamata odds, data dal rapporto tra la probabilità di successo p_i e la probabilità di insuccesso $1-p_i$, cioè:

$$odds_i = \frac{p_i}{1-p_i} = \frac{P(Y_i=1)}{P(Y_i=0)} \tag{2.19}$$

Sostituendo le espressioni per p_i e $1-p_i$, otteniamo:

$$\text{odds}_i = \frac{\frac{e^{\mathbf{x}_i'\beta}}{1+e^{\mathbf{x}_i'\beta}}}{\frac{1}{1+e^{\mathbf{x}_i'\beta}}} = e^{\mathbf{x}_i'\beta} \tag{2.20}$$

Essendo esso il rapporto tra due probabilità, varia tra 0 e $+\infty$ Ed è ancora non lineare nelle variabili esplicative e nei parametri. Dall'$odds_i$ possiamo considerare il suo logaritmo:

$$\log(odds_i) = \log(\frac{p_i}{1-p_i}) = \log(e^{\mathbf{x}_i'\beta}) = \mathbf{x}_i'\beta = \text{logit}(p_i) \tag{2.21}$$

Il logit(p_i) è lineare nei parametri e nelle variabili esplicative e varia tra $-\infty, +\infty$. Ecco perché si parla di modello logistico e di modello logit in modo interscambiabile.

2.3.1 Stima dei parametri

Per la stima dei parametri nel modello logit, si deve ricorrere al metodo della massima verosimiglianza. Sia n la dimensione campionaria e sia Y_i una variabile di risposta binaria che rappresenta l'esito di un evento, dove $Y_i = 1$ indica un successo e $Y_i = 0$ un insuccesso, per $i = 1, 2, \ldots, n$. Sia $\mathbf{x}_i = (1, x_{i1}, x_{i2}, \ldots, \mathbf{x}_{ik})'$ il vettore $(k+1)$-dimensionale, che contiene le informazioni sulle k variabili esplicative associate all'unità i-esima, più l'intercetta. Sia $\beta = (\beta_0, \beta_1, \ldots, \beta_k)$ il vettore dei parametri incogniti da stimare associati a $\mathbf{x}_i'$.
La densità di Y_i, dato $\mathbf{x}_i'$ può essere scritta come:

$$f(Y_i|\mathbf{x}_i') = p_i^{Y_i} * (1-p_i)^{1-Y_i} = F(\mathbf{x}_i'\beta)^{Y_i} * (1-F(\mathbf{x}_i'\beta))^{1-Y_i} \tag{2.22}$$

dove $F(\mathbf{x}_i'\beta)$ è la funzione di ripartizione, che nel caso del modello logit è quella della distribuzione logistica.

$$f(Y_i|\mathbf{x}_i') = \Lambda(\mathbf{x}_i'\beta)^{Y_i} * (1-\Lambda(\mathbf{x}_i'\beta))^{1-Y_i} \tag{2.23}$$

che sarà uguale a $F(\mathbf{x}_i'\beta)$ in caso di successo ($Y_i = 1$), e a $1-F(\mathbf{x}_i'\beta)$ in caso di insuccesso ($Y_i = 0$). Consideriamo la probabilità congiunta per le n unità statistiche:

$$L(\beta) = \prod_{i=1}^{n} f(Y_i|\mathbf{x}i') = \prod_{i=1}^{n} \Lambda(\mathbf{x}_i'\beta)^{Y_i} * (1-\Lambda(\mathbf{x}_i'\beta))^{1-Y_i} \tag{2.24}$$

Passando alla log-verosimiglianza:

$$
\begin{aligned}
l(\beta) &= \log(L(\beta)) \\
&= \log\left(\prod_{i=1}^{n} \Lambda(\mathbf{x}_i'\beta)^{Y_i} * (1 - \Lambda(\mathbf{x}i'\beta))^{1-Y_i}\right) \\
&= \sum_{i=1}^{n} \left[Y_i * \log\left(\Lambda(\mathbf{x}_i'\beta)\right) + (1 - Y_i) * \log\left(1 - \Lambda(\mathbf{x}_i'\beta)\right)\right]
\end{aligned}
\tag{2.25}
$$

Per trovare le stime di massima verosimiglianza del vettore β, $\hat{\beta}$, bisogna massimizzare la log-verosimiglianza.

$$
\hat{\beta} = \underset{\beta}{\operatorname{argmax}}\ l(\beta) \tag{2.26}
$$

Le derivate prime sono date da:

$$
\begin{aligned}
\frac{\partial}{\partial\beta} l(\beta) &= 0 \\
\frac{\partial}{\partial\beta} \sum_{i=1}^{n} \left[Y_i * \log(\Lambda(\mathbf{x}_i'\beta)) + (1 - Y_i) * \log(1 - \Lambda(\mathbf{x}i'\beta))\right] &= 0 \\
&\dots \\
\sum_{i=1}^{n} (Y_i - \Lambda(\mathbf{x}_i'\beta))\mathbf{x}_i' &= 0
\end{aligned}
\tag{2.27}
$$

Poiché siamo in presenza di modelli non lineari nei parametri, la soluzione del problema non può essere ottenuta in forma chiusa. Bisogna ricorrere ad algoritmi numerici, come ad esempio il Metodo di Newton-Raphson, un algoritmo numerico per trovare lo zero di una funzione sapendo che questo esiste ed è unico e che la funzione è derivabile. È anche chiamato metodo delle tangenti. È utilizzabile in tutti quei casi in cui non sia possibile esplicitare la stima di log-verosimiglianza (perché non in forma chiusa).
Per farlo è necessario derivare l'Hessiano (cioè le derivate seconde) come segue:

$$
\begin{aligned}
\frac{\partial}{\partial\beta}\frac{\partial}{\partial\beta'} l(\beta) &= \frac{\partial}{\partial\beta} \sum_{i=1}^{n} (Y_i - \Lambda(\mathbf{x}_i'\beta))\mathbf{x}_i' \\
&\dots \\
&= \sum_{i=1}^{n} \lambda(\mathbf{x}_i'\beta)\mathbf{x}_i'\mathbf{x}_i \\
&= \sum_{i=1}^{n} \Lambda(\mathbf{x}_i'\beta)(1 - \Lambda(\mathbf{x}_i'\beta))\mathbf{x}_i'\mathbf{x}_i \\
&= \sum_{i=1}^{n} p_i(1 - p_i)\mathbf{x}_i'\mathbf{x}_i
\end{aligned}
\tag{2.28}
$$

Una volta stimati i coefficienti associati a ciascuna variabile e averli validati, possiamo passare alla valutazione della bontà di adattamento del modello.

2.3.2 Odds Ratio

Nel contesto della regressione logistica, il concetto di Odds Ratio (OR) svolge un ruolo centrale nell'interpretazione dei risultati del modello. Introdotta nella parte conclusiva della sezione 2.2 la definizione di odds, questa risulta fondamentale per procedere alla definizione dell'Odds Ratio che, come dice anche il nome, è definito come rapporto tra Odds, considerando un caso binario dove sia D_i una variabile binaria, a cui è associato un parametro δ. Possiamo definire l'Odds per $D_i = 1$ e l'Odds per $D_i = 0$:

$$odds(Y_i = 1|D_i = 1) = \frac{P(Y_i = 1|D_i = 1)}{P(Y_i = 0|D_i = 1)} = e^{\beta_0+\delta} \tag{2.29}$$

$$odds(Y_i = 1|D_i = 0) = \frac{P(Y_i = 1|D_i = 0)}{P(Y_i = 0|D_i = 0)} = e^{\beta_0} \tag{2.30}$$

Ora possiamo definire l'Odds Ratio per D_i, che è dato dal rapporto tra gli Odds per $D_i = 1$ e per $D_i = 0$:

$$\text{odds ratio}(D_i) = \frac{odds(Y_i = 1|D_i = 1)}{odds(Y_i = 1|D_i = 0)} = \frac{e^{\beta_0+\delta}}{e^{\beta_0}} = e^{\delta} \tag{2.31}$$

L'esponenziale di δ, o nel nostro caso dei singoli β_i, permette di calcolare l'impatto delle singole variabili indipendenti sulla variabile di risposta. Distinguiamo di seguito tre casi in cui è possibile classificare l'Odds Ratio:

- $\beta_i = 0$, allora Odds Ratio $= 1$ e quindi la variabile X_i non ha alcun effetto sugli Odds;
- $\beta_i > 0$, allora Odds Ratio > 1 il quale implica che un aumento della variabile X_i ha un effetto positivo sugli Odds dell'evento e sulla probabilità associata ad esso;
- $\beta_i < 0$, allora Odds Ratio < 1 il quale implica che un aumento della variabile X_i ha un effetto negativo sugli Odds dell'evento e sulla probabilità associata ad esso.

Più precisamente, è possibile valutare il valore degli Odds Ratio come un aumento o diminuzione percentuale della probabilità che si verifichi l'evento successo. Ad esempio, calcolare un Odds ratio pari a 1.67 significa che per ogni incremento di una unità di X_i, gli Odds di successo aumentano di circa il 67%.

2.4 Valutazione della bontà di adattamento del modello

Dopo aver stimato i coefficienti, sono necessarie diverse fasi per valutare l'adeguatezza e l'utilità del modello. In primo luogo, l'importanza di ciascuna delle variabili esplicative viene valutata effettuando test statistici sulla significatività dei coefficienti. Viene quindi testata la bontà complessiva di adattamento del modello, successivamente, viene valutata la capacità del modello di discriminare tra i due gruppi definiti dalla variabile di risposta.

2.4.1 Pseudo-R^2

Nei modelli a variabile dipendente limitata si utilizza la massima verosimiglianza per arrivare a ottenere le stime dei parametri, si arriva alle stime attraverso un processo iterativo e non minimizzando la varianza. Ciò comporta che l'approccio dei minimi quadrati per la bontà

di adattamento non può essere applicato. Sono stati sviluppati diversi pseudo-R^2, chiamati così perché sono simili all'R^2, nel senso che variano tra 0 e 1, anche se in alcuni casi viene violato questo range.
Alti valori indicano un buon adattamento al modello, ma non è possibile interpretare i valori come nel caso dei minimi quadrati. Prendiamo a riferimento in particolare, lo pseudo-R^2 di Cox-Snell e lo pseudo-R^2 di Nagelkerke:

- R^2 di Cox-Snell:
$$R^2_{cs} = 1 - (\frac{L_0}{L_{modello}})^{\frac{2}{n}} \tag{2.32}$$
dove $L_{modello}$ è la verosimiglianza del modello stimato e L_0 è la verosimiglianza del modello nullo, ossia con la sola intercetta. Questo rapporto riflette il miglioramento del modello stimato rispetto al modello nullo con la sola intercetta.
- R^2 di Nagelkerke (o Cox-Snell normalizzato):
$$R^2_n = \frac{R^2_{cs}}{\max(R^2_{cs})} \tag{2.33}$$

2.4.2 Analisi dei residui

L'analisi dei residui costituisce una fase fondamentale nella valutazione della qualità e dell'affidabilità di un modello statistico, incluso un modello logit. Nei modelli logit, dove la variabile dipendente può assumere valori binari, i residui non presentano le stesse proprietà di quelli riscontrabili nei modelli di regressione lineare, nonostante ciò, l'analisi dei residui continua a essere cruciale per identificare eventuali discrepanze tra le osservazioni reali e le probabilità previste dal modello, e per diagnosticare problemi potenziali quali specificazione inadeguata, influenze anomale o errori nella selezione delle variabili esplicative.
Nel contesto di un modello logit, i residui possono essere esaminati attraverso diverse metodologie, tra cui i residui di devianza e i residui di Pearson. Questi strumenti permettono di valutare l'adattamento del modello e di identificare la presenza di eventuali pattern sistematici che possano suggerire una cattiva specificazione del modello o la necessità di includere ulteriori variabili esplicative o termini non lineari. L'analisi dei residui viene effettuata principalmente attraverso l'uso di strumenti grafici statistici, come il Marginal Model Plot, il Residual Plot e il QQ-Plot.

2.5 Valutazione della capacità predittiva del modello

In aggiunta alle statistiche relative alla valutazione dell'adeguatezza del modello, un ulteriore aspetto che viene preso in considerazione è la capacità predittiva del modello. Nella maggior parte dei casi, infatti, oltre ad essere interessati a conoscere se il modello è in grado di prevedere adeguatamente $P(Y_i = 1)$ possiamo essere interessati anche a voler verificare se il modello è in grado di prevedere adeguatamente l'appartenenza dei casi ad un gruppo o ad un altro, quindi siamo interessati alla tabella delle classificazioni. Nella regressione logistica la tabella delle classificazioni è una tabella a due vie (2 × 2) nella quale, per ciascuna osservazione, si pongono a confronto i valori osservati con i valori previsti dal modello. Per

fare ciò, bisogna innanzitutto passare dalla probabilità stimata al valore stimato della variabile di risposta binaria.

$$\hat{p}_i \in [0,1] \rightarrow \hat{y}_i \in \{0,1\} \tag{2.34}$$

Per fare ciò, bisogna stabilire una threshold (cutoff o soglia) ottimale, che ci aiuta nell'assegnare una unità statistica ad un gruppo oppure all'altro; in modo che se $\hat{p}_i > k$ allora $\hat{y}_i = 1$.
In genere k = 0.5, ma questo presuppone che $P(Y_i = 1) = P(Y_i = 0) = 0.5$, e ciò non è sempre vero.
Convenzionalmente la categoria 0 è detta negativa, mentre la categoria 1 è detta positiva.

Tabella 2.1: Matrice di confusione

	Valori veri		
Valori previsti	$y_i = 0$	$y_i = 1$	
$\hat{y}_i = 0$	$n_{00} = \text{TN}$	$n_{01} = \text{FN}$	$n_{00} + n_{01} = \text{TN} + \text{FN}$
$\hat{y}_i = 1$	$n_{10} = \text{FP}$	$n_{11} = \text{TP}$	$n_{10} + n_{11} = \text{FP} + \text{TP}$
	$n_{00} + n_{10} = \text{TN} + \text{FP}$	$n_{01} + n_{11} = \text{FN} + \text{TP}$	$n = \text{TN} + \text{FN} + \text{FP} + \text{TP}$

2.5.1 Elementi della matrice di confusione

Quindi, come denotabile dalla Tabella 2.1, possiamo distinguere diversi elementi che costituiscono la matrice di confusione, dai quali è possibile costruire alcune misure di performance del nostro modello:

- n_{00} individua il numero di unità statistiche che sono assegnate alla categoria 0, e che sono effettivamente nella categoria 0. Quindi sono i True Negative (TN, i Veri Negativi). In termini probabilistici, si ha la probabilità di avere un vero negativo, ossia:

$$TN = P(\hat{Y}_i = 0 | Y_i = 0) \tag{2.35}$$

- n_{01} individua il numero di unità statistiche che sono assegnate alla categoria 0, e che sono nella categoria 1. Quindi sono i False Negative (FN, i Falsi Negativi). In termini probabilistici, si ha la probabilità di avere un falso negativo, ossia:

$$FN = P(\hat{Y}_i = 0 | Y_i = 1) \tag{2.36}$$

- n_{10} individua il numero di unità statistiche che sono assegnate alla categoria 1, e che sono nella categoria 0. Quindi sono i False Positive (FP, i Falsi Positivi). In termini probabilistici, si ha la probabilità di avere un falso positivo, ossia:

$$FP = P(\hat{Y}_i = 1 | Y_i = 0) \tag{2.37}$$

- n_{11} individua il numero di unità statistiche che sono assegnate alla categoria 1, e che sono effettivamente nella categoria 1. Quindi sono i True Positive (TP, i Veri Positivi).

In termini probabilistici, si ha la probabilità di avere un vero positivo, ossia:

$$TP = P(\hat{Y}_i = 1 | Y_i = 1) \tag{2.38}$$

Vediamo ora le principali misure di performance calcolabili a partire dalle componenti appena individuate:

- *Accuratezza o tasso di corretta classificazione*: definito come la proporzione di unità statistiche assegnate correttamente. Varia tra 0 e 1. Più si avvicina ad 1, e migliore è il modello.
$$acc = \frac{TP + TN}{TP + TN + FP + FN} \tag{2.39}$$
- *Errore di classificazione o misclassificazione*: definito come la proporzione di unità statistiche non assegnate correttamente. Varia tra 0 e 1. Più si avvicina a 0, migliore è il modello.
$$err = 1 - acc = 1 - \frac{TP + TN}{TP + TN + FP + FN} = \frac{FP + FN}{TP + TN + FP + FN} \tag{2.40}$$
- *False Positive Rate (FPR)*: definito come la proporzione di unità statistiche non assegnate correttamente alla categoria 1. Varia tra 0 e 1. E' un falso allarme. Può essere calcolato anche come il complemento ad 1 della specificità. Se i positivi sono pochi, FPR può essere alto, portando ad una situazione in cui il predetto positivo è molto probabilmente un negativo.
$$FPR = \frac{FP}{TN + FP} \tag{2.41}$$
- *False Negative Rate(FNR)*: definito come la proporzione di unità statistiche non assegnate correttamente alla categoria 0. Varia tra 0 e 1. C'è un trade off tra i FPR e FNR. Se uno è alto, l'altro è basso. Possono essere ricollegati all'errore di primo e secondo tipo.
$$FNR = \frac{FN}{TP + FN} \tag{2.42}$$
- *True Positive Rate (TPR o Sensitivity)*: definito come la proporzione di unità statistiche assegnate correttamente alla categoria 1. Varia tra 0 e 1.
$$TPR = \frac{TP}{TP + FN} \tag{2.43}$$
- *True Negative Rate (TNR o Specificity*: definito come la proporzione di unità statistiche assegnate correttamente alla categoria 0. Varia tra 0 e 1.
$$TNR = \frac{TN}{TN + FP} \tag{2.44}$$

Di seguito vediamo come queste misure interagiscono tra loro permettendoci di creare un utile strumento grafico per comprendere al meglio le capacità predittive del nostro modello.

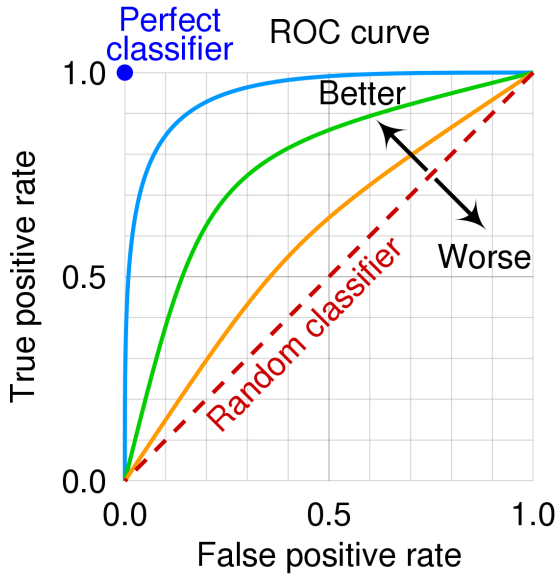


Figura 2.1: Curva ROC ottimale

2.5.2 Curva ROC e AUC

La Curva Receiver Operating Characteristic (ROC) è uno strumento grafico utilizzato per valutare la performance di un classificatore binario. Essa rappresenta la relazione tra il tasso di veri positivi (True Positive Rate, o TPR) e il tasso di falsi positivi (False Positive Rate, o FPR), per differenti soglie di classificazione.
L'Area sotto la Curva ROC (AUC - Area Under the Curve) fornisce una misura complessiva dell'accuratezza del classificatore. Un AUC più elevato denota una migliore capacità del modello di distinguere tra le classi positive e negative, rendendolo un indicatore sintetico della qualità del classificatore su tutte le possibili soglie di decisione.
Il posizionamento della Curva ROC nel plot, come indicato dalla figura 2.1, fornisce informazioni sulla qualità del classificatore binario. Di seguito spieghiamo in che modo è possibile interpretare la curva in relazione alla sua posizione e all'AUC:

- Curva vicina all'angolo superiore sinistro: è il segno di un buon classificatore. Una curva che si avvicina all'angolo in alto a sinistra indica un alto tasso di veri positivi (TPR) con un basso tasso di falsi positivi (FPR). Il modello ha una buona capacità di discriminare tra le classi positive e negative. In questo caso, l'AUC sarà molto vicino a 1, segnalando un'ottima performance.
- Curva lungo la diagonale (linea rossa tratteggiata): se la Curva ROC si sovrappone alla diagonale che collega l'angolo inferiore sinistro con l'angolo superiore destro del grafico, il modello sta classificando in modo casuale. In questa situazione, il classificatore non riesce a distinguere tra le classi. Il valore dell'AUC sarà vicino a 0.5, che equivale a una previsione casuale.
- Curva sotto la diagonale: Se la Curva ROC si posiziona al di sotto della diagonale, significa che il classificatore si comporta peggio di una classificazione casuale. Questo

può accadere quando il modello inverte le predizioni, assegnando più falsi positivi che veri positivi. Un AUC inferiore a 0.5 indica un classificatore estremamente inefficace, poiché può addirittura peggiorare le previsioni rispetto al caso casuale.

Dopo aver concluso la panoramica teorica riguardante i principali strumenti statistici utilizzati, vediamo come applicarli al caso studio introdotto nella sezione 1.5.

3 Caso studio: Volley Salerno nella stagione 23/24

3.1 Metodologie di raccolta dei dati

Per poterci approcciare in maniera concreta al caso studio è fondamentale introdurre il contesto e le metodologie di raccolta dei dati. La squadra soggetto dell'analisi, partecipante al campionato campano di Serie D nella stagione sportiva 2023/2024, è la A.S.D. Volley Salerno Official; in particolare la squadra ha partecipato al primo dei due gironi (girone A) della competizione.
Sulle venti partite analizzabili di campionato, tra girone di andata e di ritorno, oltre ad alcune gare di precampionato, il totale di gare esaminate è pari a dieci, tutte posizionabili nella prima parte di stagione, in particolare consideriamo sette delle dieci partite del girone di andata oltre a tre partite di precampionato giocate contro avversari di pari categoria o di categoria superiore (serie C).
I dati sono stati raccolti attraverso la visione e contestuale registrazione delle variabili presenti nel dataset da parte del sottoscritto seguendo le linee guida concordate con lo staff tecnico della società, utilizzate anche da match analyst di alto livello del settore; nella sezione successiva verrà approfondito il contenuto del dataset e la spiegazione delle variabili registrate, in particolare i punti registrati nella matrice di dati, e quindi ogni record, sono relativi ad un singolo punto giocato durante la fase di cambio-palla, fase in cui la squadra considerata, partendo dalla ricezione, necessita di fare punto per riconquistare il servizio. I valori relativi ad ogni singolo punto sono stati inseriti asincronamente, attraverso la visione dei filmati delle partite giocate, permettendo quindi di ridurre l'errore di valutazione che potrebbe verificarsi svolgendo la stessa mansione in tempo reale; si specifica che alcune delle valutazioni risultano essere soggettive, proprio per far fronte a questa potenziale problematica le valutazioni sono state effettuate sempre dalla stessa persona e nel corso della stessa giornata per ogni partita, in modo da abbassare, quanto più possibile, le differenze nella valutazione di situazioni simili.

3.2 Analisi esplorativa dei dati

Ritornando alla registrazione di un record (riga) di dati, questo avviene nel momento in cui la squadra avversaria effettua una battuta che supera la rete che divide la metà campo e cade nella porzione di campo della squadra oggetto di studio, quando ciò accade vengono registrati:

- La posizione da cui proviene la battuta;
- Il tipo di battuta del giocatore avversario;
- La rotazione in cui si trova la squadra oggetto di studio;
- La rotazione in cui si trova la squadra avversaria;
- La posizione occupata dal giocatore che riceve il pallone;
- L'angolo con cui il giocatore che riceve impatta la palla;
- Il valore associato alla qualità della ricezione;
- La distribuzione degli attacchi effettuati durante il punto;

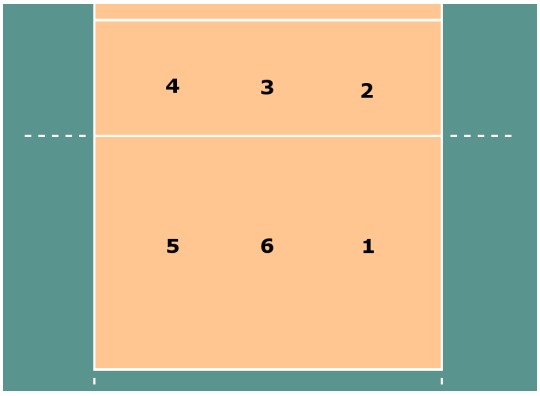


Figura 3.1: Suddivisione in zone del campo di pallavolo

- l'esito del punto;
- e infine il modo in cui è stato concluso il punto.

Per un totale di osservazioni contenute nel dataset di 510.

Rispetto agli eventi sopra elencati, osserviamo le seguenti variabili all'interno del dataset:

- Matchday_fac: fattore con dieci livelli contenente il nome identificativo della squadra avversaria;
- Competizione_fac: fattore con tre livelli (Memorial, Amichevole, Campionato) indicante il tipo di competizione in cui si è giocata la partita;
- Casa_Trasferta_fac: variabile dummy indicante il luogo di svolgimento della partita, assume valore 0 per le partite in trasferta/campo neutro e 1 per le partite in casa;
- Set_fac: fattore con cinque livelli (da 1 a 5) indicante il set di riferimento in cui si è giocato il punto registrato;
- Rotazione_fac: fattore con sei livelli (P1, P2, ..., P6) indicante la rotazione di partenza della squadra oggetto di studio, in ricezione, secondo i canoni tattici del gioco della pallavolo;
- Rotazione_avv_fac: fattore con sei livelli (P1, P2, ..., P6) indicante la rotazione della squadra avversaria in battuta secondo i canoni tattici del gioco della pallavolo;
- Pos_Battitore_fac: fattore con tre livelli (A1, B6, C5) indicante la zona antistante al punto da cui viene effettuata la battuta;
- Tipo_Battuta_fac: fattore con tre livelli (F, JF, S) indicante il tipo di battuta che viene effettuato dal battitore avversario;
- Pos_Ricettore_fac: fattore teoricamente composto da sei livelli (da 1 a 6, formalmente da cinque poichè non ci sono record per ricezioni da zona 4) indicante la zona occupata in campo dal ricettore seguendo la suddivisione classica del campo di pallavolo in 6 zone, osservabile nella figura 3.1:
- Angolo_Ricezione_fac: fattore con dieci livelli indicante la posizione del corpo che il giocatore assume durante l'esecuzione del fondamentale di ricezione (ad esempio per H si intendono tutti i tipi di palleggio o colpi sopra la testa, per MF, Middle-Forward, si intende un pallone colpito in bagher frontalmente e piegati in avanti, ecc.), precisazione

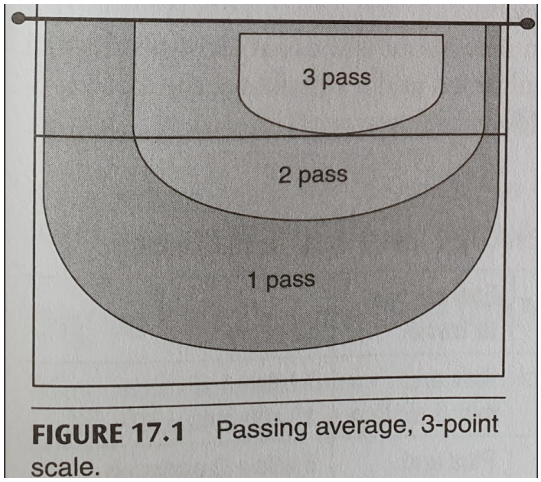


Figura 3.2: Schema di assegnazione del punteggio alla ricezione per area

importante è per il livello NA che include tutti i casi in cui la squadra subisce un ace (punto diretto) senza che ci sia un tentativo di intercettare il pallone.

- Score_Ricezione_fac: fattore con quattro livelli (da 0 a 3) indicante la qualità della ricezione, assegnato in base alla posizione e all'altezza in cui il palleggiatore (o chi effettua il secondo tocco) impatta il pallone, la valutazione generalmente viene valutata in primis per la posizione in cui cade l'alzata a cui viene sottratto un punto se l'alzata non viene effettuata dal palleggiatore e un punto se chi alza non può effettuare l'alzata in palleggio o in posizione comoda (ad es. necessita di abbassarsi o contorcersi per alzare). Seguendo lo schema di assegnazione del punteggio riportato nella Figura 3.2.
- Score_Ricezione: la variabile precedente ma riportata come numerica;
- Banda: variabile di conteggio indicante il numero di volte in cui il palleggiatore alza il pallone, nel corso della stessa azione, al giocatore che ricopre il ruolo di banda in prima linea;
- Centrale: variabile di conteggio indicante il numero di volte in cui il palleggiatore alza il pallone, nel corso della stessa azione, al giocatore che ricopre il ruolo di centrale in prima linea;
- Opposto: variabile di conteggio indicante il numero di volte in cui il palleggiatore alza il pallone, nel corso della stessa azione, al giocatore che ricopre il ruolo di opposto;
- Palleggiatore: variabile di conteggio indicante il numero di volte in cui il palleggiatore non alza il pallone, nel corso della stessa azione, provando ad attaccare;
- Banda2: variabile di conteggio indicante il numero di volte in cui il palleggiatore alza il pallone, nel corso della stessa azione, al giocatore che ricopre il ruolo di banda in seconda linea;
- Punto_fac: variabile dummy indicante l'esito del punto giocato (dove 0 indica punto perso mentre 1 indica punto vinto);
- Punto: versione numerica della variabile Punto_fac;
- Punto_M_fac: fattore con 23 livelli indicante la modalità o causa di conclusione del

punto, tale variabile è risultata utile soprattutto nel corso della stagione come supporto alle decisioni dello staff tecnico della squadra.

3.2.1 Analisi grafica

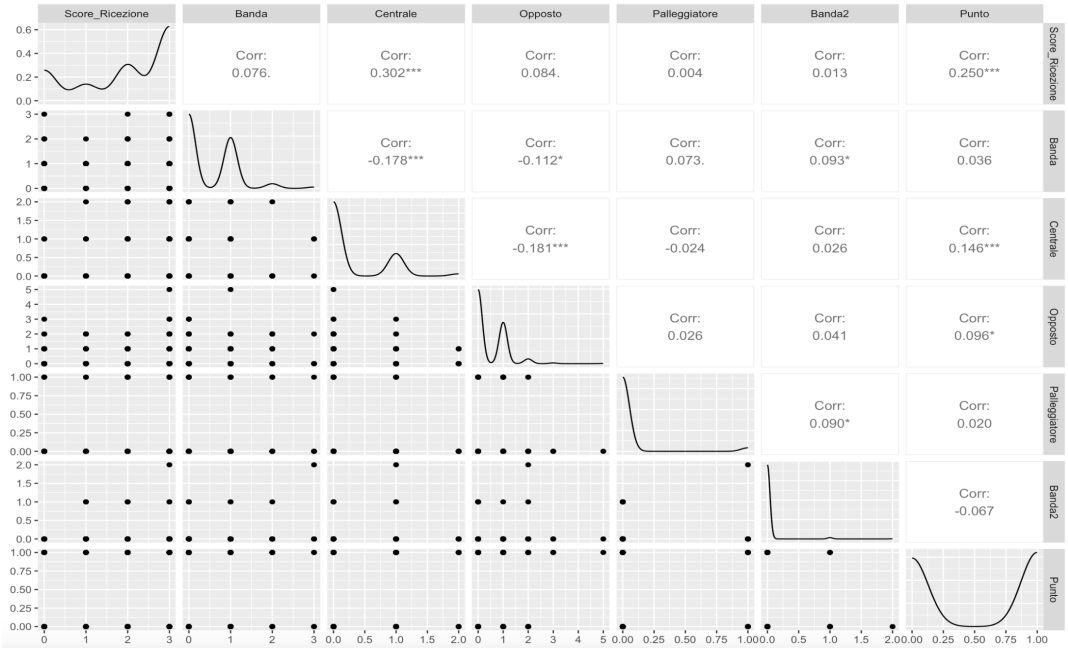


Figura 3.3: Pair Plot delle variabili numeriche

Attraverso l'analisi del pair plot (Figura 3.3), per le variabili numeriche contenute nel dataset, possiamo vedere anche la matrice di correlazione tra le covariate. Esistono correlazioni interessanti tra la variabile Punto e lo Score_Ricezione, così come tra la variabile Punto e la variabile Centrale entrambe positive. Ci aspettavamo questo tipo di relazione positiva in quanto generalmente si tende a giocare con i centrali solo quando vi è un ottima ricezione (score 2/3, correlazione anche qui positiva pari a 0.302) inoltre, l'attacco proveniente da questi giocatori è risolutivo o mette in forte difficoltà la squadra avversaria.
Lo schema di correlazioni si avvicina all'importanza dei ruoli nella pallavolo dal punto di vista offensivo, nella pallavolo moderna, infatti, il ruolo più impattante soprattutto nelle serie minori risulta essere quello degli opposti (0.096) e dei centrali (0.146), più difficile vedere l'impatto dei giocatori di banda e tanto meno dei palleggiatori.
Il pair plot ci permette anche di valutare la distribuzione delle nostre variabili numeriche, i giocatori che vengono coinvolti più spesso in maniera ripetuta all'interno di un singolo punto sono bande e opposti, in minima parte ciò accade per i centrali, anche per quanto detto in precedenza.
Come visibile dalla Figura 3.4 la distribuzione della posizione del ricettore è leggermente sbilanciata a favore della zona 6. Il risultato non è inaspettato in quanto la zona 6 è la zona centrale del campo ed è a più riprese presidiata dai liberi che hanno come loro punto di forza la ricezione, motivo per cui lo sbilanciamento ritrovato non risulta anomalo.

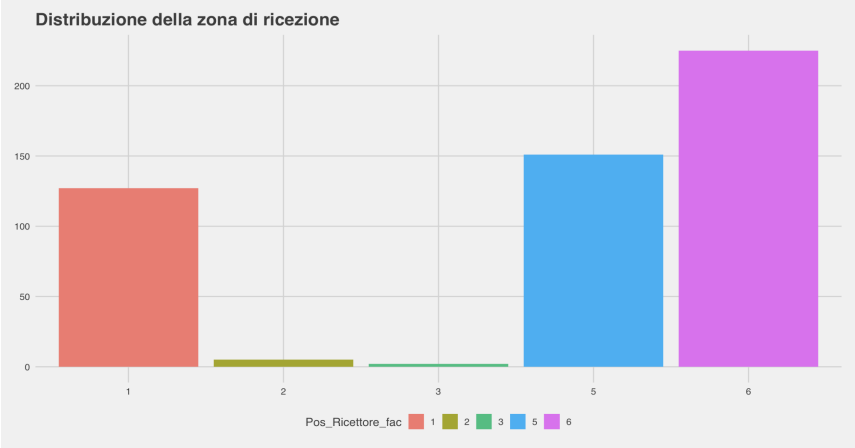


Figura 3.4: Distribuzione della zona di ricezione

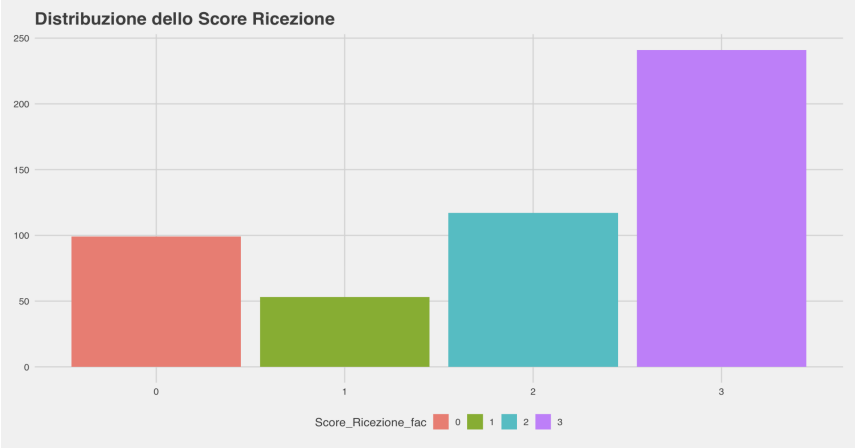


Figura 3.5: Distribuzione dello score della ricezione

L'impatto della qualità della ricezione sull'esito del punto è facilmente osservabile dal barplot contenuto nella figura 3.6 che mostra un sensibile decremento delle ricezioni valutate con lo score massimo e un notevole incremento delle ricezioni valutate con lo score minimo in corrispondenza dell'esito di punto non conquistato (0). In particolare il numero di ricezioni perfette diminuisce di circa 60 unità, mentre il numero di ricezioni pessime aumenta di circa 40 unità; in termini percentuali le due differenze indicate valgono un decremento dell'11% e un aumento di circa l'8.5% rispettivamente.
Per quanto riguarda la variabile Angolo_Ricezione è possibile vedere come la maggior parte delle ricezioni (53.5%) avvengono in palleggio (H) o in bagher frontrale (MF).
Osservando il barplot relativo alla modalità di conclusione del punto (Figura 3.8) è possibile notare come si possano distinguere un buon numero di categorie relative solo alla mancata conquista del punto (ad es. Ricezione, Palleggiatore_2, le variabili Ruolo_MS e le Difesa_x, fatta eccezione un osservazione), altre categorie relative esclusivamente alla conquista del punto (ad es. Errore_Avv) e un ultimo folto gruppo "ibrido" che ricade in entrambe le casistiche (si pensi in primis agli attacchi), in funzione di ciò potremmo calcolare l'efficacia

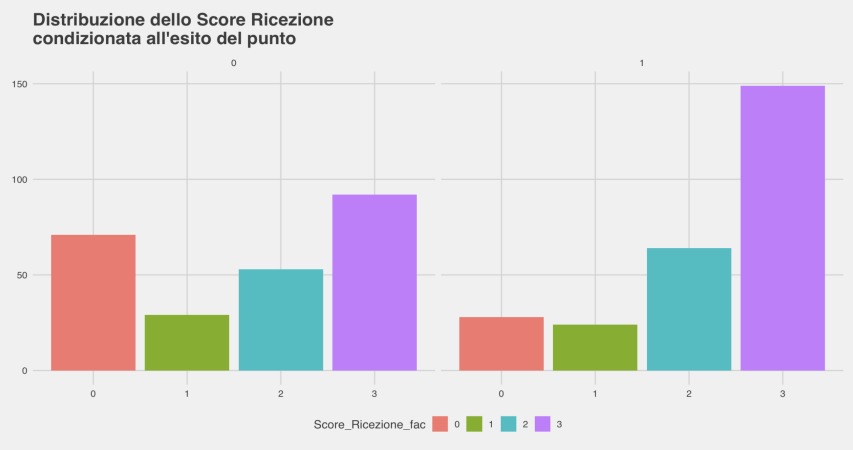


Figura 3.6: Distribuzione dello score della ricezione condizionato all'esito del punto

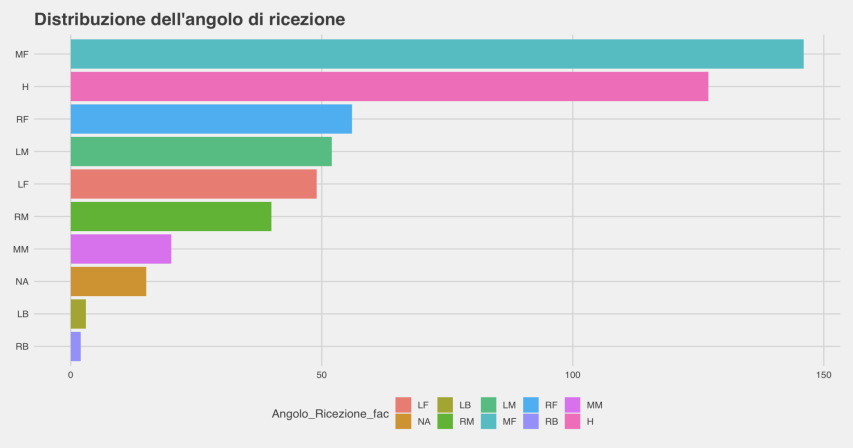


Figura 3.7: Distribuzione dei punti per angolo di ricezione

degli attaccanti (per ruolo) utilizzando il rapporto tra punti vinti e persi in fase di attacco.

3.3 Stima del modello logit

Procediamo alla stima del modello logit seguendo le tecniche e la teoria introdotta all'interno del Capitolo 2, più precisamente decidiamo di scegliere le variabili che ci permettono di trarre degli insight dai dati riguardo alla probabilità di vincere un punto tenendo bene a mente la significatività dei risultati e dei coefficienti stimati, oltre alla coerenza di tali risultati con il panorama tattico e tecnico delineato dal gioco della pallavolo.
Il modello logit per il calcolo della probabilità di vittoria di un punto selezionato partendo dai predittori presenti nel dataset sopra presentato ed analizzato è il seguente (3.1):

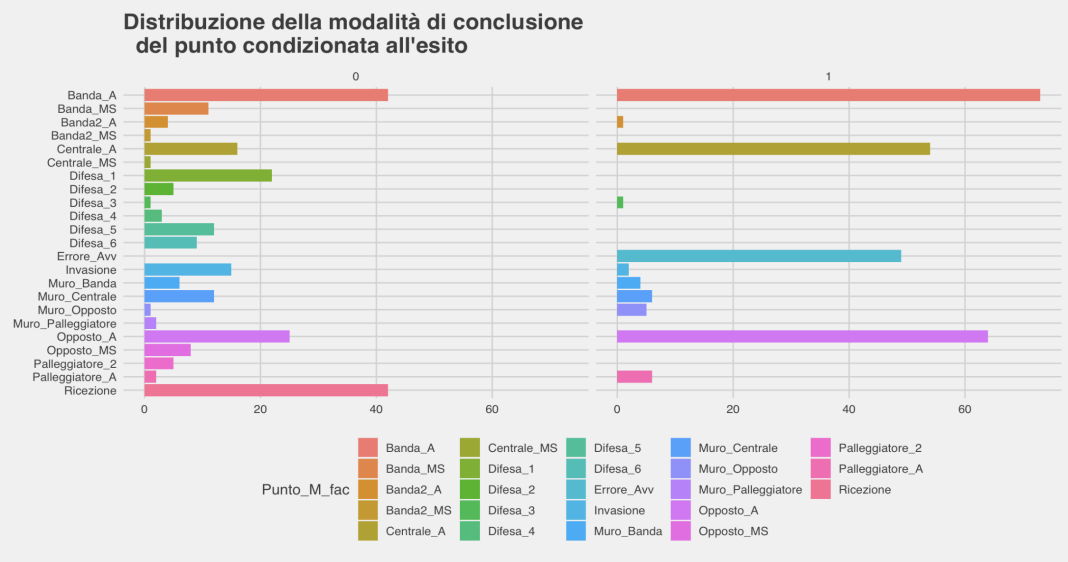


Figura 3.8: Distribuzione della modalità di conclusione del punto rispetto all'esito

$$\begin{aligned}\text{logit}(P(Punto = 1)) = \beta_0 &+ \beta_1 \cdot Score_Ricezione1 \\ &+ \beta_2 \cdot Score_Ricezione2 + \beta_3 \cdot Score_Ricezione3 \\ &+ \beta_4 \cdot Competizione_Campionato \\ &+ \beta_5 \cdot Matchday_Sparanise + \beta_6 \cdot Matchday_Volla \\ &+ \beta_7 \cdot Opposto + \beta_8 \cdot Centrale + \beta_9 \cdot Banda2\end{aligned} \tag{3.1}$$

Dove:

- $\text{logit}(P(Punto = 1))$ è il logit della probabilità che la variabile dipendente $Punto$ sia pari a 1;
- β_0 è il termine noto (intercetta);
- $\beta_1, \beta_2, \ldots, \beta_9$ sono i coefficienti di regressione delle variabili indipendenti.

Commentiamo ora le stime ottenute per i coefficienti della regressione logistica.

3.3.1 Interpretazione della stima dei parametri

Nella Tabella 3.1 è presente la stima dei parametri del modello logit con la rispettiva significatività statistica, analizziamo tale stima al fine di effettuare delle prime osservazioni sul fenomeno.

L'intercetta rappresenta il log-odds di vincere un punto quando tutte le variabili esplicative sono uguali a zero. Un valore negativo indica che, in assenza di altri effetti, la squadra ha meno probabilità di vincere un punto rispetto a perderlo.

Un aumento del livello di Score_Ricezione_fac è associato a un aumento dei log-odds di vincere un punto. In particolare, rispetto alla categoria di riferimento (che è la ricezione con

Tabella 3.1: Stima dei parametri del modello logit e significatività

Coefficients	**Estimate**	**Std. Error**	**Pr(|z|)**	
Intercetta	-1.4610	0.2713	7.27e-08	***
Score_Ricezione1	0.7625	0.3712	0.03994	*
Score_Ricezione2	1.0668	0.3085	0.00054	***
Score_Ricezione3	1.2151	0.2834	1.80e-05	***
Competizione_Campionato	0.4800	0.2104	0.02253	*
Matchday_Sparanise	1.0617	0.4017	0.00822	**
Matchday_Volla	-1.1214	0.4560	0.01393	*
Opposto	0.3820	0.1580	0.01558	*
Centrale	0.5138	0.2119	0.01533	*
Banda2	-1.1647	0.6378	0.06782	.

la qualità inferiore), avere una ricezione di qualità 1, 2, o 3 aumenta significativamente la probabilità di vincere un punto, con un incremento maggiore all'aumentare della qualità della ricezione.
Partecipare a una partita di campionato, rispetto ad una partita amichevole aumenta la probabilità di fare punto, questo è dovuto all'impiego durante le amichevoli della maggior parte dei giocatori a disposizione e non soltanto dei titolari schierati abitualmente nel corso del campionato.
Giocare contro Sparanise sembra aumentare significativamente la probabilità di fare punto, suggerendo che l'avversario potrebbe essere meno competitivo rispetto al livello di riferimento ossia la squadra ARES. Giocare contro Volla, al contrario, riduce significativamente la probabilità di fare punto, confermando di essere una delle squadre più temibili del campionato, quanto detto è in linea con i risultati ottenuti dalle squadre considerate a termine del campionato, esposti nella tabella 1.1.
Utilizzare l'opposto nel corso di un'azione aumenta i log-odds di vincere un punto. Questo effetto è significativo e suggerisce che l'opposto contribuisce positivamente alla probabilità di vincere un punto, non a caso sia a livello professionale che non gli opposti risultano essere i giocatori che in media conquistano più punti nel corso di una partita, oltre ad essere i giocatori che vengono remunerati maggiormente.
Similmente a quanto accade con l'opposto, coinvolgere nel gioco i centrali come attaccanti comporta un aumento dei log-odds di vincere un punto. Anche questo effetto è significativo.
Infine, utilizzare la banda in seconda linea (Banda2) come attaccante è associato ad una diminuzione dei log-odds di vincere un punto. Questo effetto, seppur marginalmente significativo, indica una tendenza negativa nel contributo di quest'ultima alla probabilità di vincere un punto, a riprova del fatto che, almeno nelle categorie inferiori, l'utilizzo di questo giocatore è legato a situazioni di necessità o di difficoltà in fase di costruzione di gioco.

3.3.2 Analisi degli OddsRatio

Come detto nella sezione 2.3.2 un ruolo importante nell'ambito della valutazione dei coefficienti di un modello logistico è dato dagli Odds Ratio. Riportiamo di seguito i valori trovati

sulla base del modello stimato e la loro interpretazione.

Tabella 3.2: Stima degli OddsRatio e significatività

Coefficients	Or	Or.Lci	Or.Uci	Pr(|z|)	
Intercetta	0.232	0.134	0.389	7.27e-08	***
Score_Ricezione1	2.114	1.037	4.462	0.0399	*
Score_Ricezione2	2.906	1.600	5.375	0.0005	***
Score_Ricezione3	3.371	1.950	5.941	1.80e-05	***
Competizione_Campionato	1.616	1.071	2.446	0.0225	*
Matchday_Sparanise	2.891	1.360	6.657	0.0082	**
Matchday_Volla	0.326	0.128	0.780	0.0139	*
Opposto	1.465	1.081	2.012	0.0156	*
Centrale	1.672	1.111	2.555	0.0153	*
Banda2	0.312	0.073	1.017	0.0678	.

L'Odds di vincere un punto quando tutte le altre variabili sono a zero è 0.232. Questo valore è significativamente inferiore a 1, suggerendo una minore probabilità di vincere il punto quando ci si trova in fase di cambio palla. L'Odds di vincere un punto con una ricezione di qualità 1 è circa il doppio rispetto alla categoria di riferimento. L'Odds di vincere un punto con una ricezione di qualità 2 è 2.906 volte superiore rispetto alla categoria di riferimento. Questo effetto è significativo. L'Odds di vincere un punto con una ricezione di qualità 3 è 3.371 volte superiore rispetto alla categoria di riferimento. Anche questo effetto è altamente significativo. Avere l'opposto come attaccante aumenta l'Odds di vincere un punto di circa il 46%, mentre utilizzare il centrale come attaccante aumenta l'Odds di vincere un punto di circa il 67% in maniera significativa. Infine, utilizzare la seconda banda come attaccante riduce l'Odds di vincere un punto a circa un terzo rispetto a non utilizzarlo.

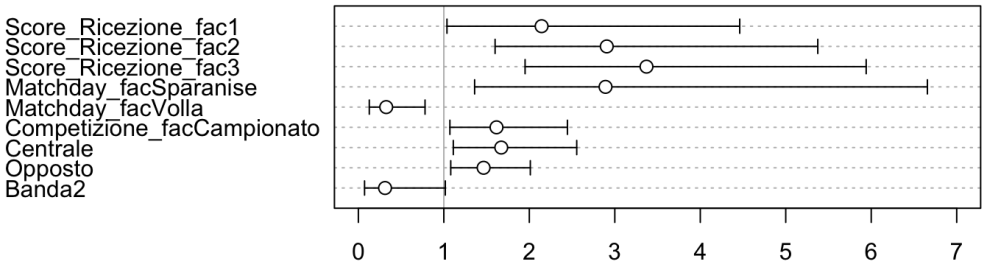


Figura 3.9: Plot degli OddsRatio

3.3.3 Diagnostica sulla collinearità

Al fine di effettuare un'accurata diagnostica sulla collinearità del modello stimato ricorriamo all'utilizzo di due metriche: il VIF e il Condition Index.

Il Variance Inflation Factor (VIF) è una misura utilizzata per quantificare l'inflazione della varianza nelle stime dei parametri, causata dalla collinearità tra i predittori all'interno di un modello di regressione. In particolare, il VIF indica l'entità con cui la varianza dei coefficienti stimati è aumentata a causa della presenza di correlazioni tra i predittori. Un VIF pari a 1 suggerisce l'assenza di correlazione tra il predittore k e le altre variabili del modello, implicando che la varianza del coefficiente associato al predittore k non è influenzata dalla collinearità con gli altri predittori.
La regola generale è che un VIF maggiore di 4, richiede ulteriori investigazioni, mentre un VIF che eccede 10 è segno di seri problemi di multicollinearità, che richiedono un'azione correttiva.

Tabella 3.3: Tolerance and Variance Inflation Factor

Variable	**Tolerance**	**VIF**
Score_Ricezione1	0.7074	1.4134
Score_Ricezione2	0.5605	1.7840
Score_Ricezione3	0.4810	2.0789
Competizione_Campionato	0.9038	1.1063
Matchday_Sparanise	0.9390	1.0648
Matchday_Volla	0.9555	1.046
Opposto	0.9393645	1.064549
Centrale	0.8650490	1.156004
Banda2	0.9872382	1.012927

Un ulteriore strumento utilizzato per la diagnostica sulla multicollinearità è il Condition Index che utilizza gli autovalori per scomporre la correlazione tra le variabili in combinazioni lineari. Queste ultime sono scelte così che la prima combinazione ha la più alta varianza (soggetta ad alcune restrizioni), la seconda combinazione ha la varianza inferiore alla precedente, soggetta al vincolo di incorrelazione con la prima, e così via con le successive. Si estraggono tante combinazioni quante sono le variabili. L'autovalore della matrice di correlazione, X^TX, ottenuta come il prodotto vettoriale della matrice trasposta dei predittori, X, e la matrice stessa, X, rappresenta la varianza della combinazione. Il Condition Index si ottiene andando a considerare la radice quadrata del più alto autovalore diviso per ciascun autovalore:

$$\text{cond ind} = \sqrt{\frac{\lambda_{\text{max}}}{\lambda_j}} \text{ per } j = 1, \ldots, k \tag{3.2}$$

Un valore di Condition Index tra 10 e 30 indica la presenza di multicollinearità, quando questo è maggiore di 30 la collinearità è da considerarsi severa.
In nessuno dei casi analizzati risultano esserci valori anomali assunti dal VIF o dal Condition Index. È possibile concludere affermando che non ci sono problemi di multicollinearità all'interno del modello stimato.

Tabella 3.4: Autovalori e Condition Index

Autovalore	**Condition Index**
3.596	1.000
1.142	1.774
1.024	1.874
0.982	1.914
0.953	1.942
0.790	2.133
0.772	2.158
0.444	2.846
0.202	4.213
0.094	6.175

3.3.4 Analisi dei residui

Affrontiamo l'analisi dei residui attraverso l'utilizzo di diversi plot, il primo utilizzato è il binnedplot.

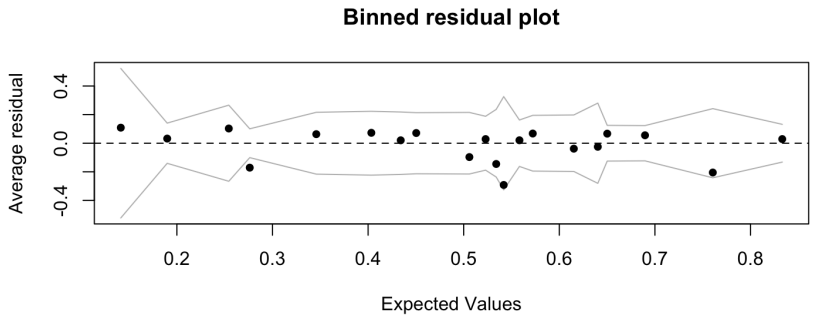


Figura 3.10: Binnedplot dei residui

Se il modello è buono, il 95% dei residui devono ricadere all'interno delle bande di errore, nel nostro caso ciò accade quindi abbiamo una prima conferma sulla bontà di adattamento del nostro modello.
Una seconda proprietà che è interessante analizzare è la distribuzione dei residui del modello, in particolare sarebbe ottimo se questi si distribuissero seguendo una distribuzione normale, a tal proposito utilizziamo il QQ-plot contenuto nella Figura 3.11; dall'analisi del quale possiamo dire che i nostri residui si distribuiscono similmente ad una Normale infatti la maggior parte dei residui si trovano nelle vicinanze della linea tratteggiata, rappresentante i quantili teorici della distribuzione Normale. Si può notare che i residui presenti nella parte destra del grafico sono etichettati, e quindi identificati come valori anomali o potenziali outliers; indagheremo questo aspetto nella sezione successiva.
Il marginal model plots (Figura 3.12) ci aiuta a capire se il modello si adatta bene ai dati. Le due linee, relative ad andamento dei dati (blu continua) e del modello (rossa tratteggiata) si sovrappongono quasi perfettamente, indicando che il modello riesce a riprodurre in maniera

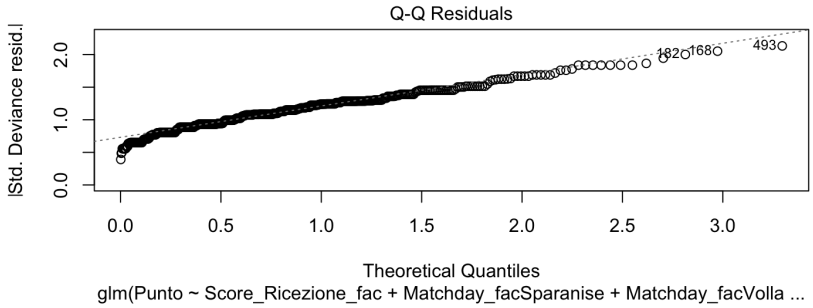


Figura 3.11: Q-Q Plot dei residui

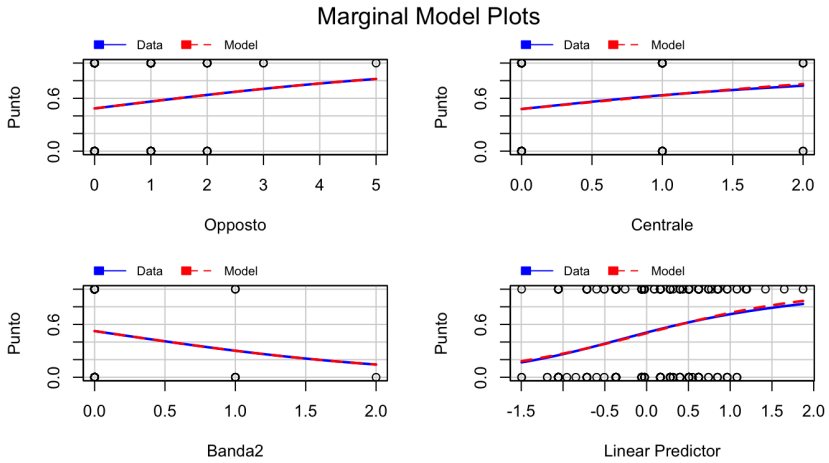


Figura 3.12: Marginal Model Plot

accurata i dati.

Nella Figura 3.13 i residui sembrano distribuirsi abbastanza uniformemente attorno alla linea zero, senza una chiara tendenza crescente o decrescente. Questo indica che il modello potrebbe essere adeguato e non vi è una chiara indicazione di non linearità.

Non sembra esserci un chiaro pattern a "ventaglio" che indichi eteroschedasticità (varianza dei residui che aumenta o diminuisce con i valori previsti). Tuttavia, ci sono delle osservazioni ai margini esterni che potrebbero suggerire un leggero aumento della varianza dei residui con valori previsti estremi, ma questo non è fortemente pronunciato. Le osservazioni etichettate, questi punti potrebbero essere considerati outliers potenzialmente influenti. È importante analizzare ulteriormente queste osservazioni per capire se stanno influenzando in modo significativo il modello.

3.3.5 Analisi dei valori anomali

Con l'outlier test è possibile controllare se ci sono valori eccezionali, nel caso in cui ci fossero, non significa che bisogna scartarli o rimuoverli, ma è necessario stare attenti ad essi. Le osservazioni sono considerate outliers se il p-value di Bonferroni a loro associato è minore di

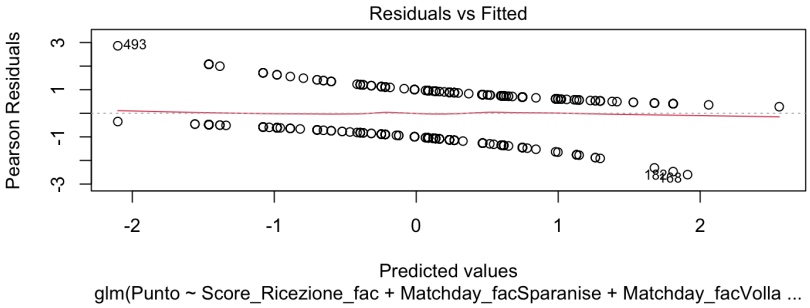


Figura 3.13: Plot dei residui vs fitted values

Tabella 3.5: Output OutlierTest

Osservazione	Rstudent	unudjusted p-value	Bonferroni p-value
493	2.155631	0.031113	NA

0.05. Nei nostri residui, come si può notare dalla Tabella 3.5, sembrerebbe che ci sia solo una osservazione (la n. 493) che presenta una situazione critica, ma il p-value di Bonferroni è mancante (NA). Ciò significa che tale osservazione non è statisticamente significativa; sebbene presenti un residuo positivo più grande, che indica che il valore osservato è più grande di quello stimato, questo valore non è statisticamente significativo.
Similmente a quanto accade con l'outlier test decidiamo di calcolare una metrica, detta Distanza di Cook, che ci permette di calcolare se un valore predetto è un outlier e in che misura, mostriamo graficamente tale metrica attraverso l'utilizzo dell'influence plot.

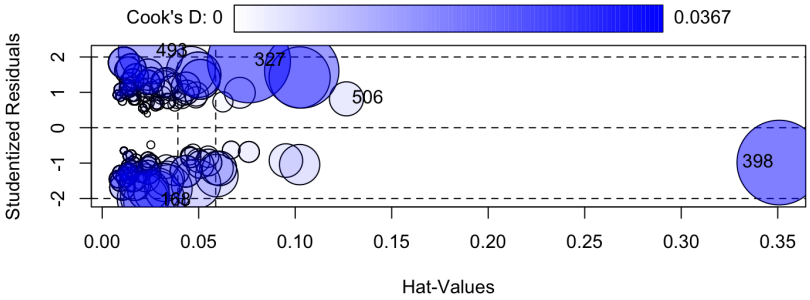


Figura 3.14: Influence Plot

L'influence plot è un grafico in cui la grandezza di ogni bubble indica la distanza di Cook. Se D (distanza di Cook) < 0.5, allora i punti non sono influenti; se D è compreso tra 0.5 e 1, allora sono potenzialmente influenti, se è maggiore o uguale ad 1, sono probabilmente influenti.
Come riportato nella Tabella 3.6, e in maniera concorde a quanto visto in precedenza con l'outlier test, ci sono cinque osservazioni che in prima battuta possono essere definite come

Tabella 3.6: Output Influnce Plot

Osservazione	Rstudent	Hat	Cook Distance
168	-2.070	0.026	0.019
327	1.882	0.076	0.035
398	-0.984	0.351	0.036
493	2.155	0.025	0.021
506	0.816	0.126	0.005

outliers. Indagando tali osservazioni la Distanza di Cook risulta essere di molto inferiore a 0.5 quindi i punti seppur outliers risultano ininfluenti.

3.3.6 Valutazione della bontà di adattamento e delle performance previsive

Nell'ambito della valutazione della bontà di adattamento e delle performance previsive del modello, è possibile adottare diversi approcci. Per quanto concerne la bontà di adattamento, uno strumento utile è lo Pseudo-R^2, una trasformazione della più generale misura di adattamento del modello ai dati, ovvero l'R^2. Questa metrica è particolarmente adatta per valutare modelli con variabile dipendente limitata. Analogamente all'R^2 tradizionale, lo Pseudo-R^2 varia tra zero e uno, con valori più prossimi a uno che indicano un migliore adattamento del modello ai dati. Tuttavia, un valore superiore a 0,4 può già essere considerato positivo. Nel nostro caso, il valore dell'R^2 di Nagelkerke è pari a 0,165, suggerendo che il conseguimento del punto non è sempre correlato a schemi di gioco facilmente modellabili, ma potrebbe essere influenzato da fattori aleatori.

Tabella 3.7: PseudoR^2

McFadden	Nagelkerke	CoxSnell
0.095	0.165	0.123

Sebbene l'obiettivo principale dello studio non sia la previsione dell'esito del punto, è comunque utile verificare le performance previsive in-sample del modello. A tal fine, si utilizzano diversi strumenti, tra cui la matrice di confusione, la curva Receiver Operating Characteristics (ROC) e la relativa Area Under the Curve (AUC), già introdotti nella Sezione 2.5.2. Le metriche associate alla curva ROC, riportate nella Tabella 3.9, mostrano valori accettabili, sebbene le valutazioni in-sample possano essere leggermente influenzate in modo positivo, con un conseguente aumento apparente dell'accuratezza. Nello specifico, si osserva una precisione molto vicina al livello complessivo di accuratezza, e un'area sotto la curva ROC pari a 0,7. Esaminando la Figura 2.1, che illustra la valutazione della curva ROC, si può concludere che, al variare delle soglie, il modello riesce a discriminare e classificare l'esito della variabile "Punto" con un discreto livello di successo.

3.4 Conclusioni e sviluppi futuri

In conclusione ricapitoliamo i risultati raggiunti nel corso dell'analisi; attraverso l'utilizzo di un modello logit è stato possibile modellare i fattori che influenzano l'esito di un punto

Tabella 3.8: Matrice di confusione

	Reference	
Prediction	**0**	**1**
0	130	66
1	115	199

Tabella 3.9: Statistiche curva ROC e AUC

Accuracy	**Sensitivity**	**Specificity**	**Precision**	**AUC**
0.645	0.751	0.531	0.634	0.705

in fase di cambio-palla all'interno dell'ambito del gioco della pallavolo a livello territoriale (Serie D campana). Tale modellazione ha portato i seguenti risultati interessanti:

1) La probabilità di vincere il punto in fase di cambio-palla, e quindi partendo in ricezione, è sensibilmente minore, circa il 77% in meno, rispetto a perderlo.
2) L'incremento nella qualità della ricezione rispetto al livello di riferimento (ricezione pessima) porta ad un incremento della probabilità di fare punto da un minimo del 3,7% ad un massimo di circa il 594%.
3) In linea con il posizionamento finale all'interno del campionato, giocare contro Volla, squadra vincitrice del campionato, comporta una diminuzione nella probabilità di vincere il punto al minimo del 12% rispetto alla categoria di riferimento, ossia la squadra ARES che ha concluso il campionato in sesta posizione su undici partecipanti.
4) L'utilizzo offensivo di determinati giocatori comporta un effetto positivo sulla probabilità di vincere il punto, in particolare ciò accade per i giocatori nel ruolo di opposto e di centrale, l'effetto risulta essere negativo per il coinvolgimento nelle azioni di attacco della banda in seconda linea (Banda2), non vi è alcun effetto significativo per il restante ruolo offensivo ossia la banda di prima linea.

Le quattro categorie di risultati ottenuti possono essere ricondotti a specifici aspetti del gioco della pallavolo, più precisamente, la prima categoria permette di mettere in evidenza il lavoro fondamentale che viene svolto dalla ricezione nella possibilità di vincere il punto e di riflesso quanto importante sia il primo fondamentale di attacco della pallavolo moderna, ossia la battuta che influenza in maniera importante la probabilità di vincere il punto; probabilmente è anche frutto di queste osservazioni che a livello professionistico, soprattutto nella pallavolo maschile, la tipologia di battuta maggiormente utilizzata, seppur con un'alta percentuale di errore, sia la battuta "spin", più potente e difficile da ricevere se ben eseguita. Contestualizzando l'utilizzo di questa tipologia di battuta al livello analizzato della Serie D campana non esiste un'evidenza statistica significativa che sia più efficace di altre tipologie. Il secondo risultato sottolinea l'impatto della qualità della ricezione sulla probabilità di fare punto e di come in queste categorie avere un sistema di ricezione efficiente ed efficace faccia la differenza tra la vittoria e la sconfitta di una partita e di interi campionati.
La terza categoria di risultati è legata propriamente al campionato appena trascorso, e aiuta a sottolineare la differenza di giocare contro la squadra vincitrice del campionato o altre

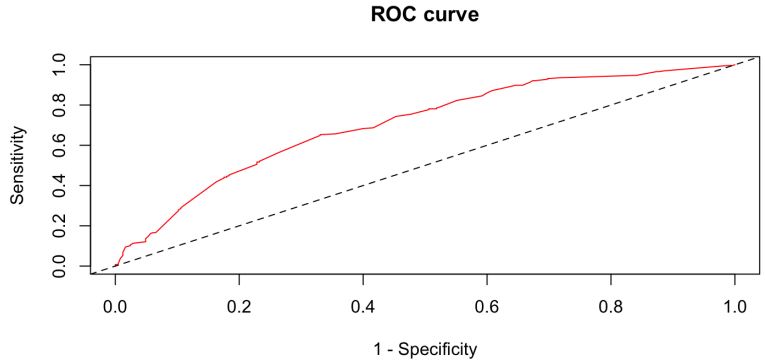


Figura 3.15: Curva ROC

compagini meno attrezzate.
L'ultima categoria di risultati permette una lettura dal punto di vista tattico e tecnico sui ruoli dei giocatori all'interno della partita; più precisamente i giocatori nel ruolo di opposto e centrale risultano essere più impattanti quando coinvolti all'interno delle azioni, dal punto di vista tattico per aumentare l'efficacia degli attacchi; è più facile che questo accada per i primi piuttosto che per i secondi. Alla luce di tali risultati sarebbe opportuno in fase di preparazione degli schemi di gioco e di studio dell'avversario cercare di far trovare i giocatori nella situazione di muro avversario a loro più congeniale per incrementare maggiormente la possibilità di fare punto.
Al fine di poter dar seguito al lavoro di tesi e ai risultati sopra riportati, oltre che un'emulazione o completamento dello stesso, considerando che le stime sono relative ad una sola squadra e gli effetti sono dunque relativi alle capacità tecniche dei singoli componenti della rosa analizzata, si potrebbe prevedere l'adozione, da parte degli enti nazionali e territoriali di pallavolo, di un sistema integrato per la raccolta dei dati relativi alle partite e alle prestazioni dei singoli giocatori, ispirato a modelli virtuosi come quello del campionato spagnolo. Tale approccio mirerebbe alla creazione di un database condiviso che raccoglie le informazioni sui giocatori e le relative statistiche, con l'obiettivo di migliorare l'efficienza nel processo di scouting, ridurre i costi associati e incrementare la qualità del gioco, inclusa quella delle serie minori. Inoltre, i giocatori avrebbero la possibilità di visionare e analizzare le proprie performance, monitorare i progressi e facilitare il lavoro di preparatori atletici, tattici e tecnici, permettendo di intervenire sulle problematiche emerse durante il gioco.
L'implementazione di un sistema di "scouting condiviso" potrebbe rappresentare una svolta significativa per l'intero movimento pallavolistico italiano. Esistono già esempi analoghi in altri sport a livello professionistico, come nel calcio con piattaforme come fbref.com o nel basket statunitense con nba.com/stats, che sfruttano la sensoristica IoT per la raccolta dei dati necessari. L'obiettivo sarebbe quello di creare una base dati condivisa a livello territoriale, partendo dalle categorie inferiori, come la Serie D, con i dovuti limiti associati alla mancanza della sensoristica, e alimentata dalle squadre partecipanti ai campionati attraverso video delle partite e relative analisi, o almeno con riepiloghi sintetici delle partite. Questa

piattaforma potrebbe essere integrata, come avviene per la federazione spagnola di pallavolo (www.rfevb.com), nella sezione dedicata ai risultati e alle classifiche di ogni competizione. In aggiunta, la diffusione dei video delle partite su piattaforme gratuite come YouTube.com potrebbe ampliare significativamente l'audience, attirando nuovi potenziali appassionati e giocatori di pallavolo, contribuendo così alla crescita del movimento sportivo nel suo complesso.

Bibliografia

[1] Enzo D'Arcangelo e Federazione Italiana Pallavolo «I TESSERATI ALLA FIPAV DAL 2010 AL 2023: UN'ANALISI STATISTICA DEI TESSERATI ALLA FEDERAZIONE ITALIANA PALLAVOLO». In: (2024). URL: https://www.federvolley.it/sites/default/files/2024-06/2%C2%B0%20QUADERNO%20FIPAV.pdf.

[2] Damodar N. Gujarati *BASIC ECONOMETRICS FIFTH (5TH)*. The logit model (pag. 599-603). McGraw-Hill, 2009.

[3] Marica Manisera e Paola Zuccolotto *Basketball Data Science with application in R*. Variability analysis (pag.40-44). CRC Press, 2020.

[4] Domenico Piccolo *STATISTICA*. Modello di regressione semplice (pag.829-837). Variabili indicatrici (pag. 888-891). Modelli per dati binari (pag. 906-912). Il Mulino, 2010.

[5] Marco Trabucchi «Data analytics negli sport, un mercato da 3 miliardi di dollari». In: *Il Sole 24 Ore* (2022).

Sitografia

[6] Federazione Italiana Pallavolo *Comitati*. 2024. URL: https://www.federvolley.it/comitati.

[7] Hai-Binh Ly *What do volleyball statistics actually mean?* 2020. URL: https://thevolleyballanalyst.wordpress.com/2020/11/11/what-do-volleyball-statistics-actually-mean/.

[8] Marica Manisera e Paola Zuccolotto *Gli statistici hanno i numeri... anche nello sport*. 2017. URL: https://www.rivista.sis-statistica.org/cms/?p=334.

[9] William Pearse *La statistica nello sport*. 2020. URL: https://inomics.com/it/blog/statistics-in-sport-1291601.

[10] Treccani *Rally point system*. URL: https://www.treccani.it/enciclopedia/rally-point-system_%28Lessico-del-XXI-Secolo%29/.

[11] Wikipedia *Storia della pallavolo*. URL: https://it.wikipedia.org/wiki/Storia_della_pallavolo.